Karlsruher Institut für Technologie
Karlsruhe Institute of Technology
Dr. Eunah Cho
Institute for Anthropomatics and Robotics, Interactive Systems Labs
eunah.cho@kit.edu

MT Praktikum - Alignment

31. Mai 2017

Um die Aufgaben auszuführen, können Sie Ihre Daten in folgendem Verzeichnis speichern:
`/project/smtstud/ss17/systems/USERNAME/`

Wir werden zunächst mit Hilfe des GIZA++ Toolkits: IBM Model 1, HMM, IBM Model 3 und IBM Model 4 trainieren und uns das resultierende Word Alignment ansehen. Dann werden wir das Training für ein IBM Model 1 Lexikon implementieren und Trainingsiterationen an einem konstruierten Beispiel durchgehen.

Sehen Sie sich die Trainingsdaten in deutsch und englisch einmal an, um einen Eindruck davon zu gewinnen, womit Sie arbeiten:
`/project/smtstud/ss17/data/corpus/train.de-en.1-99.de`
`/project/smtstud/ss17/data/corpus/train.de-en.1-99.en`

Bitte melden Sie sich nach Abschluss jeder Aufgabe (oder ggf. Zwischenaufgabe), sodass wir ausschließen können, dass Sie mit fehlerhaften Dateien weitermachen. Melden Sie sich bitte auch, wenn eine angegebene Laufzeit für ein Programm stark überschritten wird.

1. **Trainieren der Word Alignment Models: Vorbereitung der Daten**

   Die parallelen Trainingsdaten müssen zunächst vorbereitet werden, da das GIZA++ Toolkit sie in einem bestimmten Format erwartet.

   (a) Führen Sie das script:
   `/project/smtstud/ss17/bin/prepare-data.sh`
   in Ihrem Verzeichnis aus und sehen Sie sich die Ausgabe und die erzeugten Dateien an. (Laufzeit ca. 4min, hauptsächlich in Schritt 1.1)

   - Schritt 1.0.5 bezieht sich auf das Trainieren faktorisierter Modelle, welche wir heute nicht verwenden werden. (D.h. dieser Schritt hat auf unsere nicht faktorisierten Daten keine Wirkung. Faktorisierte Übersetzungsmodelle werden in der Vorlesung später besprochen.)

- Schritt 1.1 berechnet die Wortklassen, die für das Trainieren von IBM Model 4 benötigt werden. Auf diesen Schritt werden wir heute nicht weiter eingehen.

- Die in Schritt 2.1a erstellten coocurrence files listen alle de-en Wortpaare auf, die in den Trainingsdaten zusammen auftauchen. Die Dateien sind die Vorlage für die Lexika.

Sehen Sie sich die Dateien aus Schritt 1.2 und 1.3 (`./corpus/de.vcb`, `./corpus/en.vcb`, `./corpus/de-en-int-train.snt`) einmal an.

- Was tun die Schritte 1.2 und 1.3?
- Wieso wird der Trainingscorpus so bearbeitet?

Antworten zu Aufgabe 1:

Schritt 1.2 erstellt eine Zuordnung von jedem Wort im Vokabular des Trainingstextes zu einem Index. Eine Indexdatei für jede Sprache.

Schritt 1.3 ersetzt die Wörter im Trainingstext mit ihren Indices und kombiniert Quell- und Zieltext in einer Datei.

Die Indices sind im Allgemeinen kürzer als die Wörter selbst, daher spart diese Vorgehensweise Speicher bei den komplexeren Modellberechnungen. Die Berechnungen sind auch schneller, da keine strings sondern nur integers verglichen werden müssen.

2. **Trainieren der Word Alignment Modelle bis zu IBM Model 4**

Verwenden Sie zum Trainieren der word alignment models das Programm:

`/project/smtstud/ss17/bin/giza/GIZA++`

(Sie können sich alle möglichen Parameter mit ihren default-Werten ansehen, wenn Sie das Programm ohne Parameter aufrufen. Wir werden nicht die Zeit haben diese alle zu besprechen.)

Berechnen Sie die Modelle zunächst in der Sprachrichtung: Quellsprache: Englisch, Zielsprache: Deutsch. Hinweis: aus historischen Gründen (noisy channel model) werden sich die Ausgabedateien hierfür im Verzeichnis: „giza.de-en“ befinden und auch das Dateipräfix de-en haben.

Verwenden Sie folgende Parameter:

(Hinweis: damit Sie nicht all diese Parameter abtippen müssen, können Sie sich den Programmaufruf hier kopieren: `/project/smtstud/ss17/bin/run.giza` – Führen Sie den Befehl in Ihrem Userverzeichnis aus, wo Sie die Daten aus Aufgabe 1 vorbereitet haben. Laufzeit ca. 6 min)

Vorbereitete Trainingsdaten einlesen:
`-CoocurrenceFile ./giza.de-en/de-en.cooc`
`-c ./corpus/de-en-int-train.snt`
`-s ./corpus/en.vcb`
`-t ./corpus/de.vcb`

Anzahl der Iterationen für jedes Modell:
`-hmmiterations 5`
`-model1iterations 5`
`-model2iterations 0` (wir verwnden das HMM model anstelle von model 2)
`-model3iterations 3`
`-model4iterations 3`

Alle Zwischenmodelle ausgeben (wir werden uns einige davon ansehen)
`-model1dumpfrequency 1`
`-hmmdumpfrequency 1`
`-model2dumpfrequency 1`
`-model345dumpfrequency 1`
`-transferdumpfrequency 1`

Ausgabeprefix:
`-o ./giza.de-en/de-en`
Bedeutung der Dateinamen der Ausgabedateien:
Datei: `./giza.t-s/t-s.xn.m`

`t`: target language (e.g. de)
`s`: source language (e.g. en)

`x`: type of table: t = word lexicon, a = alignment model, A = alignment, n = fertilities, d = distortion model, p0 = probability, that the NULL word is not inserted
`n`: model number (z.B. model 1 oder hmm, aus historischen Implementationsgründen sind model 4 files zum Teil als höhere model 3 Iterationen geführt, z.B. de-en.A3.5 ist tatsächlich das Alignment der 2. Iteration model 4)
`m`: iteration number

(a) Sehen Sie sich die Perplexität der Traingsdaten für die verschiedenen Modelle und Iterationen an. (Hinweis: diese finden Sie sowohl in der Logdatei des Trainings train.giza.log als auch zusammengefasst in der Datei `giza.de-en/de-en.perp`)

- Wie entwickelt sich die Perplexität der Trainingsdaten und warum?

(b) Sehen Sie sich das Wortlexikon aus dem Model 1 Training Iteration 5 (`giza.de-en/de-en.t1.5`) und aus dem Model 4 Training (`giza.de-en/de-en.t3.final`) an. (Lexikonformat: EN DE probability)

- Finden Sie die jeweils die 3 wahrscheinlichsten Übersetzungen für das englische „you“.

  Hinweis:
  1. Verwenden Sie die beiden Vokabularien: `giza.de-en/de-en.trn.src.vcb` und `giza.de-en/de-en.trn.trg.vcb`.
  2. Befehl: `grep ‘‘^6 ’’ giza.de-en/de-en.t1.5 |sort -g -k 3`

- Wie unterscheiden sich die Lexika und warum?

model 1		model 4	
you - Sie	0.7641	you - Sie	0.9048
you - ?	0.0742	you - Ihnen	0.0689
you - Ihnen	0.0475	you - sie	0.0086
you - können	0.0422	you - schön	0.0036
you - ,	0.0259	you - Du	0.0021

(c) Vergleichen Sie die Alignment Dateien aus der jeweils letzten Iteration von Model 1 Training (`giza.de-en/de-en.A1.5`) und aus dem Model 4 Training (`giza.de-en/de-en.A3.final`).

- Finden Sie das Alignment für Satz Nummer 11 in beiden Dateien und tragen Sie die alignment links jeweils unten ein:

  Model 1 Training (Iteration 5) `giza.de-en/de-en.A1.5`

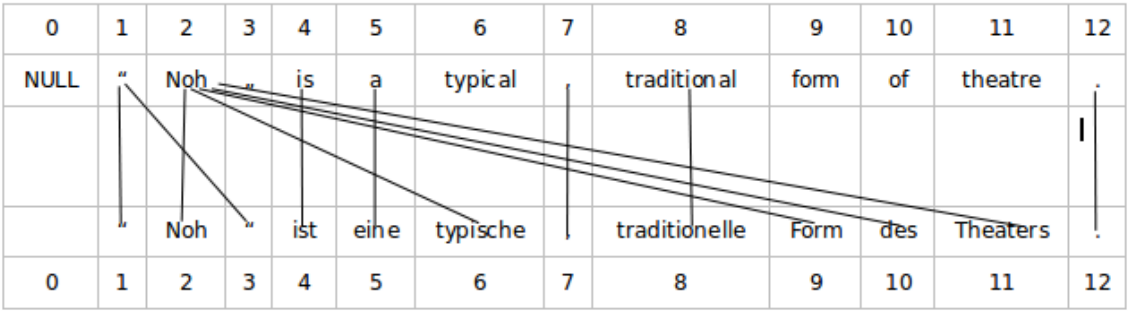

  Model 4 Training (Iteration 3) `giza.de-en/de-en.A3.final`

- Was können Sie hier ablesen?

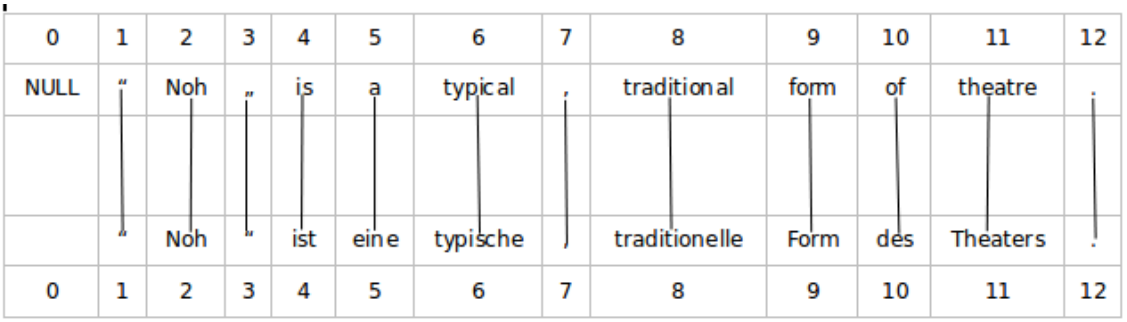

Trainieren Sie nun alle Modelle für die umgekehrte Sprachrichtung: Führen Sie den Befehl in `/project/smtstud/ss17/bin/run.giza.rev` in Ihrem User-verzeichnis aus, wo Sie die Daten aus Aufgabe 1 vorbereitet haben. (Laufzeit ca. 6 min)

(d) Vergleichen Sie die Alignment Dateien aus der letzten Iteration model 1 aus den beiden Trainingsrichtungen. (`giza.de-en/de-en.A1.5` und `giza.en-de/en-de.A1.5`)

- Finden Sie das Alignment für Satz Nummer 106855 (am Ende der Dateien) in beiden Dateien und tragen Sie die alignment links jeweils unten ein:

Model 1 Training (Iteration 5) forward `giza.de-en/de-en.A1.5`

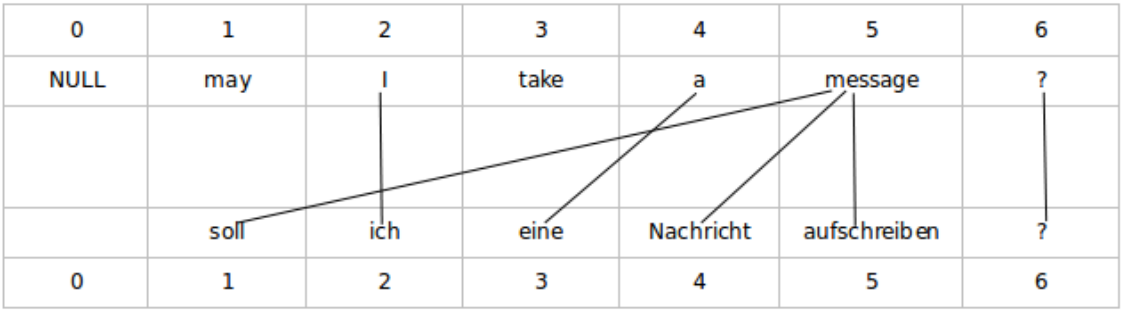

Model 1 Training (Iteration 5) reverse `giza.en-de/en-de.A1.5`

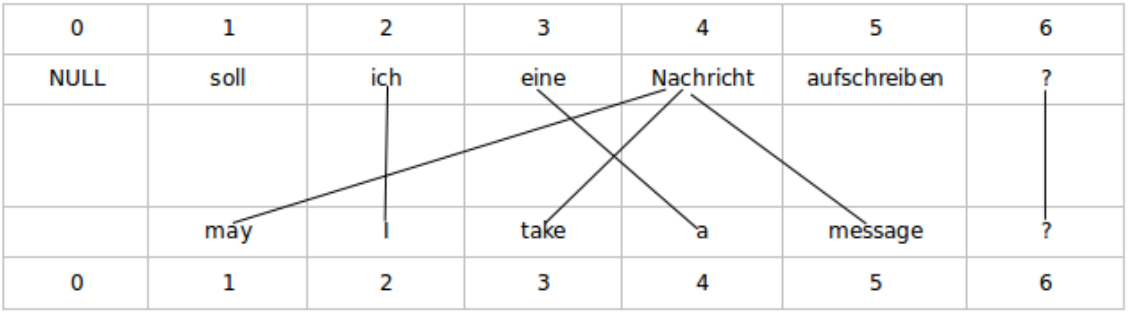

- Was lässt sich an diesem Beispiel deutlich ablesen?

Antworten für Aufgabe 2:

2.a) Die Perplexität sinkt mit jeder Iteration.

2.b) Die Wahrscheinlichkeiten sind schärfer, d.h. sie grenzen stärker zwischen richtig und falsch ab. Das model 4 Lexikon hat deutlich weniger Einträge für das Wort „you“, da mehr falsche Übersetzungen unter den Pruning threshold gefallen sind.

2.c) Das Alignment wird besser. Da das model 1 keine Positionsinformation hat, kann es im Alignment nicht zwischen dem ersten und den zweiten Anführungszeichen unterscheiden, höhere models aber schon.

2.d) Hier kann man deutlich sehen, dass die beiden Richtungen asymmetrisch sind. Nach dem model 1 Training macht das System im Grunde denselben Alignmentfehler, aber weil jeweils in nur einer Richtung one-to-many alignments erlaubt sind, wird das Alignment asymmetrisch.

3. **Implementierung: IBM model 1 (Zusatzaufgabe)**

Das IBM1 Modell wird benutzt um ein word alignment und ein Lexikon für einen Satz-alinierten Corpus zu generieren. Schreiben sie ein Programm, das ein Lexikon und einen Corpus als Eingabe bekommt und danach einen Schritt des EM-Algorithmus zum Trainieren des IBM1 Modell vollführt.

Falls Sie das in Perl/Python programmieren möchten, können Sie folgende Vorlage verwenden: `/project/smtstud/ss17/bin/IBM1.pl` oder `/project/smtstud/ss17/bin/IBM1.py` (Hinweis: Nehmen Sie den Pseudocode aus der Vorlesung zur Hilfe.)

Das initiale Lexikon und die Beispielsätze aus der Vorlesung finden sie im Verzeichnis: `/project/smtstud/ss17/data/smallExample`

- Wie verändern sich die lexikalischen Wahrscheinlichkeiten mit den Iterationen?
- Wie viele Iterationen scheinen Ihnen in diesem Fall sinnvoll?

Möglichen Lösungen für den Pseudo-Code: /project/smtstud/ss17/bin/IBM1loesung.py, /project/smtstud/ss17/bin/IBM1loesung.pl)

DE	EN	init	Iteration 1	Iteration 2	Iteration 3	...	Iteration ?
Haus	house	0.25	0.50	0.571428	0.65338		0.91723
Haus	the	0.25	0.50	0.428571	0.34661		0.08276
das	house	0.25	0.25	0.181818	0.13126		0.00461
das	the	0.25	0.50	0.636363	0.74789		0.99330
das	book	0.25	0.25	0.181818	0.12084		0.00208
ein	a	0.25	0.50	0.571428	0.65338		0.91723
ein	book	0.25	0.50	0.428571	0.34661		0.08276
Buch	the	0.25	0.25	0.181818	0.12084		0.00208
Buch	a	0.25	0.25	0.181818	0.13126		0.00461
Buch	book	0.25	0.50	0.636363	0.74789		0.99330